

# 基于 ANFIS 改进的大气腐蚀环境缺失数据 填补方法

石雅楠<sup>a</sup>, 付冬梅<sup>a</sup>, 支元杰<sup>a</sup>, 陈闽东<sup>b</sup>

(北京科技大学 a.自动化学院; b.新材料技术研究院, 北京 100083)

**摘要:** 目的 针对大气腐蚀中重要环境数据缺失的复杂问题, 提出一种相关因素(Relevance Factors)和自适应神经模糊推理系统(Adaptive Neuro-Fuzzy Inference System)结合的方法(RF-ANFIS)对缺失数据进行填补。**方法** 首先采用相关因素方法计算缺失数据和多项环境因素间的相关程度, 筛选出相关系数较大的因子, 然后应用 ANFIS 构建缺失数据与所选环境因子的关系模型。最后以二氧化硫数据为具体对象, 采用北京 2015 年的气象数据对所建立的模型进行检验。**结果** 经过改进的 RF-ANFIS 模型在最优情况下样本均方误差为 0.696, 在 14 个测试样本中有 13 个相对误差在 20% 以内, 针对有限样本的数据分析中更为适用。**结论** 该方法有效提高了大气腐蚀环境数据缺失的填补精度, 对在数据缺失情况下预测大气腐蚀速率具有重要意义。

**关键词:** 大气腐蚀; 缺失数据; 相关因素; ANFIS

**DOI:** 10.7643/issn.1672-9242.2016.06.014

**中图分类号:** TJ01; TG172.3

**文献标识码:** A

**文章编号:** 1672-9242(2016)06-0078-07

## Improved ANFIS-based Imputation Method for Missing Data on Atmospheric Corrosion Environment

SHI Ya-nan<sup>a</sup>, FU Dong-mei<sup>a</sup>, ZHI Yuan-jie<sup>a</sup>, CHEN Min-dong<sup>b</sup>

(a. School of Automation; b. Institute of Advanced Materials and Technology, University of Science and Technology Beijing, Beijing 100083, China)

**ABSTRACT: Objective** To propose a new method (RF-ANFIS) based on relevance factors and Adaptive Neuro-Fuzzy Inference System to impute missing important environmental data on atmospheric corrosion. **Methods** The relevance degree between missing data and a number of environmental factors was calculated through relevance factors. Factors of high relevance degree were selected; then a relationship model between missing data and environmental factors was built through ANFIS. Finally, SO<sub>2</sub> data was taken as the specified object to test the model according to atmospheric data of Beijing in 2015. **Results** The error of mean square of samples in the improved RF-ANFIS model was 0.696 in the best case. The relative error of 13/14 test

收稿日期: 2016-07-12; 修订日期: 2016-08-12

Received: 2016-07-12; Revised: 2016-08-12

基金项目: 国家重点基础研究发展计划项目(2014CB643300); 国家科技基础性工作专项(2012FY113000)

Fund: Supported by The National Basic Research Program of China(2014CB643300); The National Science and Technology Basic Work(2012FY113000).

作者简介: 石雅楠(1993—), 女, 辽宁人, 硕士研究生, 主要研究方向为大气腐蚀数据挖掘的研究。

Biography: SHI Ya-nan(1993—), Female, from Liaoning, Master graduate student, Research focus: atmospheric corrosion data mining.

通讯作者: 付冬梅(1963—), 女, 辽宁人, 博士, 教授, 主要研究方向为智能数据分析的研究。

Corresponding author: FU Dong-mei(1963—), Female, from Liaoning, Doctor, Professor, Research focus: intelligent data analysis.

samples was within 20%. It was applicable to data analysis of limited samples. **Conclusion** The new method effectively improves the accuracy of imputing environmental data in atmospheric corrosion. It is vital to predict atmospheric corrosion rate with missing data.

**KEY WORDS:** atmospheric corrosion; missing data; relevance factors; ANFIS

大气腐蚀中缺失数据的填补是建模与应用中重要且具有一定难度的研究课题。根据 ISO 9223—2012 标准，金属大气的腐蚀速率与环境中的二氧化硫浓度、氯化物浓度、温度以及湿度四个因子息息相关，但这些腐蚀因子由于人为疏忽、信息获取的滞后性等客观因素常有缺失，因此探索合适的精确度高的填补方法是实际工程亟待解决的难题。

目前腐蚀数据的处理方法主要集中在灰色模型<sup>[1—4]</sup>和 BP 网络<sup>[5—7]</sup>。灰色系统中较常用的 GM(1,1)模型仅适用于单变量对输出变量的预测，如利用一维时间序列建模，这种方法可获取信息少，无法考虑多维环境因素对腐蚀因子的影响。BP 网络虽然可用于多维数据，但其需要大量的样本和长时间的训练才能得到较为准确的结果，且容易产生局部最优和过拟合，在腐蚀数据样本量有限时预测效果往往不理想。近年来专家将模糊神经网络逐渐应用于腐蚀数据的分析<sup>[8—11]</sup>，模糊神经网络有效融合了模糊推理系统和神经网络的优点，在一定程度上克服了由于原始数据样本量过小而影响预测效果的问题。当数据样本维度较高时，模糊神经网络结构的特殊性会导致维数灾难而无法计算，

所以如何有效实现降维就成了解决问题的一个途径。

基于上述原因，文中以二氧化硫缺失数据的填补为例，不同于传统利用多维环境因素或在一维时间序列上预测大气数据的单一模式，而将二者充分结合以挖掘更多信息，并通过相关因素(Relevance Factors)对所构建的 ANFIS(Adaptive Neuro-Fuzzy Inference System)进行简化，进而建立二氧化硫的缺失预测填补模型。该研究对工程应用中填补二氧化硫一类有限样本的腐蚀数据具有实际意义。

1 数据收集与预处理

文中的数据来源于腐蚀站点提供的北京 2015 年 3 月 19 日至 2015 年 6 月 5 日的环境数据和腐蚀数据。环境数据含有气温、风力、湿度、天气状况、降水量、PM2.5、PM10、O<sub>3</sub>、NO<sub>2</sub> 共 9 个因素，腐蚀数据即二氧化硫浓度。文中选用了统一的 Excel 表格进行规范化，MATLAB 可以方便地将数据导入和导出表格。气象数据的采集是按小时进行的，每小时采一次，一天应有 24 组数据，表 1 仅列出了北京市某一天的 10 条数据。

表 1 部分原始环境数据和腐蚀数据  
Table 1 Part of the original environmental data and corrosion data

日期	时间	气温/℃	风力/级	相对湿度/%	天气状况	降水量/mm	PM2.5/(μg·m <sup>-3</sup> )	PM10/(μg·m <sup>-3</sup> )	O <sub>3</sub> /(μg·m <sup>-3</sup> )	NO <sub>2</sub> /(μg·m <sup>-3</sup> )	SO <sub>2</sub> /(μg·m <sup>-3</sup> )
3/19	0:35	8	1	43	阴	0	171	94	14	25	10
3/19	1:35	9	1	40	阴	0	172	36	14	31	16
3/19	2:35	9	2	41	阴	0	162	55	13	31	16
3/19	3:35	9	2	42	阴	0	163	56	13	32	17
3/19	4:35	10	2	34	阴	0	163	49	13	33	15
3/19	5:35	10	2	35	阴	0	160	60	14	26	14
3/19	6:35	11	1	33	阴	0	161	69	16	26	14
3/19	7:35	11	2	37	阴	0	156	59	18	22	12
3/19	8:35	12	1	38	阴	0	122	59	20	17	10
3/19	9:35	11	1	39	晴	0	132	64	22	16	9

ISO 9223—2012 标准中统计二氧化硫浓度的最小单位为日,所以数据预处理的目的是将原始小时化的数据转换成以日为单位的样本,填补目标也为二氧化硫的日平均浓度。首先将所有数据量化,根据风力等级表将风力转换成区分度更高的风速。研究表明<sup>[12]</sup>,日照时间是影响腐蚀的重要因素之一,而日照时间可通过每小时的天气状况(晴、阴、多云、雨雪等)推断得到,对天气状况处理时将晴记为1,其他情况记为0。然后将数据进行转换,每日的日照时间和降水量由相应每小时的数据累加得到,而其他所有因素则求日平均值作为对应数据。最后经过数据预处理后共得到79个样本用于研究。

## 2 RF-ANFIS 模型

模糊神经网络的结构具有多样性的特点,比较常用的是 Jang 提出的 ANFIS 系统。实际应用中,网络生成的模糊规则数为各输入变量的隶属度函数个数之积(例如网络有  $m$  个输入变量,每个变量隶属度函数个数为  $n$ ,模糊规则数即为  $n^m$ )。因此在隶属度函数个数(一般取 3~5)变化不大的情况下,网络的输入变量不宜过多,否则生成的规则数过大不易于实现<sup>[13]</sup>。针对 ANFIS 这一应用中的问题,文中引入相关因素的分析降低网络的复杂性,进而提出了一种 RF-ANFIS 预测模型,结构如图1所示。

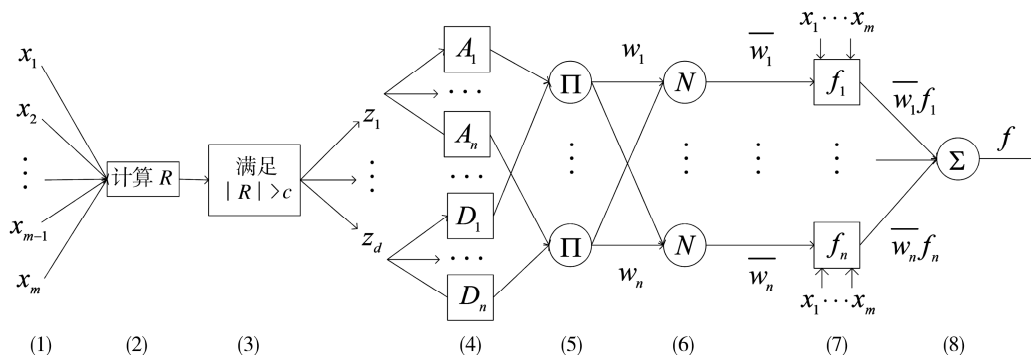


图1 RF-ANFIS 预测模型结构

Fig.1 Structure of RF-ANFIS prediction model

第一层为所有变量的输入层,假定输入变量为  $m$  维,则输出函数为:

$$O^1 = x_k \quad k=1,2,\dots,m \quad (1)$$

第二层为相关因素计算层,计算每个输入变量  $x_k$  与输出变量  $y$  之间的相关系数。相关因素分析是研究随机变量之间是否存在某种依存关系,并对具体有依存关系的现象探讨其相关方向以及相关程度的一种统计方法。相关系数  $R$  表示相关方向和相关程度。 $R$  在(0,1)之间为正相关,在(-1,0)之间为负相关,等于1为完全正相关,-1为完全负相关,0为不相关。变量  $x_k$  与变量  $y$  之间的相关性系数公式为:

$$O^2 = R_{x_k y} = \frac{\sum_{l=1}^n (x_{kl} - \bar{x}_k)(y_l - \bar{y})}{\sqrt{\sum_{l=1}^n (x_{kl} - \bar{x}_k)^2 \times \sum_{l=1}^n (y_l - \bar{y})^2}} \quad (2)$$

式中:  $x_{kl}$  和  $\bar{x}_k$  表示输入变量  $x_k$  的第  $l$  个样本值和样本均值;  $y_l$  和  $\bar{y}$  表示输出变量  $y$  的第  $l$  个样

本值和样本均值。

第三层为相关因素判断层,通过相关性系数的大小对输入变量进行取舍。设定一个常量  $c$ ,判断规则为若  $|R|$  大于  $c$  则将对输入变量输出至下一层,否则留在这一层。由此已将  $m$  维的原始数据降至  $d$  维 ( $d < m$ )。

$$O^3 = \begin{cases} Z_r & R_{x_k y} > c \\ \text{无} & R_{x_k y} \leq c \end{cases} \quad k=1,2,\dots,m; r=1,2,\dots,d \quad (3)$$

第四层为降维后的输入变量的隶属函数层,负责输入信号的模糊化。对于一阶 Takagi-Sugeno 模糊系统具有如下模糊规则:

规则  $i$ : if  $z_1$  is  $A_i$  and  $z_2$  is  $B_i$ ... and  $z_d$  is  $D_i$  then  $f_i = p_i z_1 + q_i z_2 + \dots + s_i z_d + r_i \quad i=1,2,\dots,n$  (4)

该层的输出函数为:

$$O^4 = \mu_{A_i}(z_1), O^4 = \mu_{B_i}(z_2), \dots, O^4 = \mu_{D_i}(z_d), \quad i=1,2,\dots,n \quad (5)$$

式中:  $z_1$  到  $z_d$  是经过相关性系数判断后选出的输入变量,  $O^4$  是  $A_i$  到  $D_i$  的隶属函数值,表示  $z_1$  到

$z_d$  分别属于  $A_i$  到  $D_i$  的程度,  $n$  是隶属度函数的个数。 $\mu_{A_i}(x)$  到  $\mu_{D_i}(x)$  可以是任意合适的参数化隶属函数, 如一般的钟型函数, 以  $\mu_{A_i}(x)$  为例:

$$\mu_{A_i}(x)=\frac{1}{1+\left|\frac{x-c_i}{a_i}\right|^{2b_i}} \tag{6}$$

式中:  $\{a_i, b_i, c_i\}$  为该节点的参数集, 称为前件参数。当这些参数改变时, 钟型参数也随之改变。

第五层为规则的强度释放层, 负责将输入信号相乘, 每个节点的输出代表该规则的可信度。输出函数为:

$$O^5=w_i=\mu_{A_i}(z_1)\times\mu_{B_i}(z_2)\times...\times\mu_{D_i}(z_d) \tag{7}$$

$i=1,2,...,n$

第六层为所有规则强度的归一化, 第  $i$  个节点计算第  $i$  条规则的归一化可信度。输出函数为:

$$O_i^6=\overline{w_i}=w_i/(w_1+w_2+...+w_n) \quad i=1,2,...,n \tag{8}$$

第七层为计算模糊规则的输出, 这一层的每个节点  $i$  为自适应节点。输出函数为:

$$O_i^7=\overline{w_i}f_i=\overline{w_i}\times(p_iz_1+q_iz_2+...+s_iz_d+r_i) \tag{9}$$

$i=1,2,...,n$

式中:  $\overline{w_i}$  为第六层的输出,  $\{p_i, q_i, ..., s_i, r_i\}$  为该节点的参数集, 称为后件参数。

第八层为一个固定节点, 计算所有输入信号的总输出, 输出函数为:

$$O_i^8=\sum\overline{w_i}f_i=\sum w_if_i/\sum w_i \quad i=1,2 \tag{10}$$

在第五层至第八层中, 通常采用一种反向传播算法和最小二乘法的混合学习算法分别对

ANFIS 的前件参数和后件参数进行训练。首先输入信号沿网络正向传播至第七层, 在前件参数不变的情况下采用最小二乘法调节后件参数, 然后信号继续沿网络正向传播直到第八层, 将获得的误差信号沿网络反向传播, 进而调节前件参数。这种方法不仅可以降低梯度法中搜索空间的维数, 而且大大提高了收敛速度<sup>[14]</sup>。

### 3 仿真过程及结果

以北京市二氧化硫为例进行仿真, 仿真过程可平移至其他环境参数缺失数据的补偿中。将 79 个样本随机分为 65 个训练样本和 14 个测试样本, 根据第 2 节中 RF-ANFIS 模型的结构逐层分析, 通过改变参数  $c$  的值改变筛选的输入变量  $d$  的个数, 并与传统仅利用多维环境因素和仅在一维时间序列上预测的方法作对比。

#### 3.1 建模步骤

1) 相关因素分析。在收集到的样本中二氧化硫是一个时序数据, 传统工程上采用滚动预测的方法建立二氧化硫缺失预测模型, 但该方法仅利用了二氧化硫自身的信息而未考虑其他因素对样本的影响。文中挖掘二氧化硫与各环境参数间的相关性, 并考虑二氧化硫自身的时序特征, 第  $t$  天的二氧化硫浓度与当日的环境数据以及前五日的二氧化硫浓度的相关性系数见表 2, 其中  $C_{t-1}$  为第  $t-1$  天的二氧化硫,  $C_{t-2}$  表示第  $t-2$  天的数据, 以此类推。

表 2 二氧化硫浓度与各因子的相关性系数  
Table 2 Relevance coefficient of the concentration of SO<sub>2</sub> and other factors

相关因素	多维环境因子								
	PM2.5	PM10	NO <sub>2</sub>	气温	风力	O <sub>3</sub>	日照时间	降水量	温度
相关系数	0.591	0.471	0.430	-0.098	-0.057	-0.045	-0.041	-0.027	-0.018

相关因素	时序因子				
	$C_{t-1}$	$C_{t-2}$	$C_{t-3}$	$C_{t-4}$	$C_{t-5}$
相关系数	0.601	0.222	-0.155	-0.088	-0.118

经过相关性分析发现, 其中二氧化硫与 PM2.5, PM10, NO<sub>2</sub>,  $C_{t-1}$ ,  $C_{t-2}$  五个因子关联性较明显。二氧化硫与前三者相关是因为雾霾天气时二氧化硫在空气中会转化成硫酸盐, 导致硫酸盐颗粒达到 40 μg/m<sup>3</sup> 以上, 致使 PM2.5, PM10, NO<sub>2</sub>

超标<sup>[15]</sup>。第  $t$  天的二氧化硫与  $t-1$  天和  $t-2$  天的相关性大也证明了其本身的自相关性。由此相关因素分析方法有效将十四维 ( $m=14$ ) 的复杂问题转化成五维 ( $d=5$ ) 的可计算网络, 同时排除了干扰因素的影响, 为 ANFIS 的建模打下基础。

2) ANFIS 建模。根据 ANFIS 的结构, 网络固定为五层。首先设定  $c=0.2$ , 此时选择出的输入变量个数  $d=5$  ( $Ct-1$ ,  $PM_{2.5}$ ,  $PM_{10}$ ,  $NO_2$ ,  $Ct-2$ ), 输出变量个数为 1, 每个输入变量的隶属度函数个数  $n=3$ 。输入的模糊隶属度函数选择钟型函数, 输出层选择一阶线性模糊推理系统即一阶 Sugeno 模糊模型, 采用网格分割法生成 FIS。网络学习算法选择混合学习算法。目标误差为 0.001, 训练次数设定为 200 次。利用训练样本训练网络, 在训练过程中, 为提高函数逼近的效果, 可对其隶属度函数类型、函数个数  $n$ 、训练次数等指标进行适当的调整。利用训练网络学习的结果对测试样本进行检测, 将预测结果与真实数据相比较, 获得样本分布图, 分析误差。

继续改变  $c$  的值, 令  $c=0.4$ , 此时选出的输入变量个数为  $d=4$  ( $Ct-1$ ,  $PM_{2.5}$ ,  $PM_{10}$ ,  $NO_2$ ), 输出变量个数仍为 1, 重复上述调参数的过程; 再令  $c=0.45$  和  $c=0.5$ , 此时选出的输入变量个数分别为  $d=3$  ( $Ct-1$ ,  $PM_{2.5}$ ,  $PM_{10}$ ) 和  $d=2$  ( $Ct-1$ ,  $PM_{2.5}$ ), 调整参数比较不同输入变量下的网络性能。

### 3.2 仿真结果

经过上述建模过程后, 将  $c$  取不同值时

RF-ANFIS 模型的预测结果与文献[7]中 BP 网络时间序列和文献[6]中 BP 网络多维因素建模的方法进行比较。表 3 是五种建模方法在误差和计算时间上的比较, 可以看出, 首先对于样本的准确率, RF-ANFIS 模型在  $c=0.4$  时不论是整体的均方误差还是单个样本的相对误差都是几种情况中最优的,  $c=0.45$  其次。当  $c=0.5$ , 输入变量减少为 2 个时, 网络性能已开始降低, 这说明仅用  $Ct-1$ ,  $PM_{2.5}$  两个输入变量做预测有偏差,  $PM_{10}$  对于二氧化硫的预测同样重要, 而  $c=0.2$  时效果也不理想。这充分说明了 ANFIS 的输入变量并不是越多越好, 相关系数为 0.222 的  $Ct-2$  加入到网络中反而对二氧化硫的预测形成了干扰。对于计算时间, BP 网络时序建模由于其网络构造的简单性用时最短, RF-ANFIS 随着  $c$  的减小, 输入变量依次增多, 使得网络生成的规则呈幂指数变化用时也就越长。因此综合上述因素, 如果不考虑计算时间, 只追求样本的精确度, 优先选择  $c=0.4$  时的 RF-ANFIS 模型; 如果在样本精确度达到一定程度时, 希望节省计算时间, 优先选择  $c=0.45$  的 RF-ANFIS 模型。

表 3 各方法参数对比  
Table 3 Comparison of different methods

比较参数	RF-ANFIS模型				BP网络	
	$c=0.5$	$c=0.45$	$c=0.4$	$c=0.2$	文献[4]时间序列	文献[7]多维因素
训练样本均方误差	0.222	4.3E-03	1.09E-06	0.0839	1.582	1.206
测试样本均方误差	1.636	1.124	0.696	1.547	2.236	2.064
训练样本相对误差<5%	49/65	63/65	65/65	58/65	15/65	21/65
测试样本相对误差<20%	10/14	11/14	13/14	8/14	5/14	7/14
运行时间/s	3.165	8.870	22.921	144.161	2.195	4.879

注: 均方误差公式为  $\frac{\sum_{i=1}^n (y_i' - y_i)^2}{n}$ , 其中  $y_i'$  和  $y_i$  分别为第  $i$  个样本的预测值和真实值,  $n$  为样本的个数。

表 4 列举了部分训练样本真实值和四种方法预测值的比较, 从单个样本的预测中可以看出,  $c=0.4$  时预测值与真实值几乎完全相同,  $c=0.45$  时误差在 1%以内, 同样与真实值近似。BP 网络的

平均误差均大于 10%, 且个别样本出现极大误差, 这也体现了 BP 网络在样本量不足的情况下准确性降低。

表 4 部分训练样本不同方法预测值和相对误差对比  
Table 4 Comparison of predicted values and relative errors of different methods in part of training samples

样本号	真实值	RF-ANFIS模型				BP网络			
		c=0.45		c=0.4		时间序列		多维因素	
		预测值	相对误差	预测值	相对误差	预测值	相对误差	预测值	相对误差
1	11.21	11.152	5.20E-03	11.214	3.57E-04	11.563	3.15E-02	10.436	6.90E-02
6	31.08	31.068	4.00E-04	31.082	6.44E-05	30.717	1.17E-02	30.154	2.98E-02
11	6.11	6.093	2.80E-03	6.105	8.18E-04	6.897	1.29E-01	6.169	9.66E-03
16	4.87	4.859	2.30E-03	4.868	4.11E-04	5.420	1.13E-01	4.675	4.00E-02
21	21.92	21.903	8.00E-04	21.915	2.28E-04	19.861	9.39E-02	19.976	8.87E-02
26	11.37	11.369	1.00E-04	11.363	6.16E-04	12.653	1.13E-01	12.820	1.28E-01
31	6.13	6.173	7.00E-03	6.129	1.63E-04	7.106	1.59E-01	6.628	8.12E-02
36	15.40	15.441	2.70E-03	15.410	6.49E-04	17.077	1.09E-01	16.861	9.49E-02
41	16.39	16.398	5.00E-04	16.389	6.10E-05	17.325	5.70E-02	15.127	7.71E-02
46	5.07	5.065	1.00E-03	5.065	9.86E-04	4.379	1.36E-01	4.233	1.65E-01
51	7.00	6.996	6.00E-04	6.998	2.86E-04	8.009	1.44E-01	6.588	5.89E-02
56	2.08	2.086	2.90E-03	2.083	1.44E-03	2.300	1.06E-01	1.418	3.18E-01
61	23.96	23.968	3.00E-04	23.959	4.17E-05	22.952	4.21E-02	22.954	4.20E-02

$c=0.4$  时的 RF-ANFIS 模型与 BP 网络时间序列和多维因素建模在测试样本上的对比如图 2 所示。这 14 个训练样本中有 9 个预测结果优于多维因素建模，13 个优于时间序列建模。由此可得，经过相关因素分析后，降低了传统 ANFIS 维数灾难的影响，有效地将难题转化为低维的可解决问题，说明应用 RF-ANFIS 模型对缺失数据的处理是可行的。同时该方法可以通过改变常量  $c$  的值控制所选择的输入变量  $d$  的个数，在经过多次仿真后寻找最佳的网络结构，结果比较理想。




图 2 三种建模方法测试样本预测值与真实值比较  
Fig.2 Comparison of predicted values and real values of three methods in test sample

4 结语

1) 相关因素的引入为 ANFIS 在多维数据样本

适用局限性的问题上提供了一种解决途径。根据腐蚀站点提供的腐蚀因子和多项环境数据进行测试，结果表明，该 RF-ANFIS 模型可以有效实现二氧化硫硫缺失数据的填补。

2) 提出的 RF-ANFIS 模型不仅可适用于二氧化硫硫，可推广至补偿同类型腐蚀因子的缺失情况。

3) 充分挖掘了多维数据之间存在的联系和时序数据本身的自相关性，为处理时序数据问题提供了新思路。

4) 相关因素分析发现气象上二氧化硫与 PM2.5, PM10, NO<sub>2</sub> 三者有紧密的关联性也是一个意外的收获。

参考文献：

[1] 黄海军, 李婵, 王俊. 典型大气腐蚀介质的灰色预测模型分析[J]. 装备环境工程, 2012, 9(1): 13—16.  
HUANG Hai-jun, LI Chan, WANG Jun. Study on Grey Prediction Model of Typical Atmospheric Corrosion Media[J]. Equipment Environmental Engineering, 2012, 9(1): 13—16.

[2] 王安东, 陈跃良, 张勇, 等. 基于灰色马尔科夫模型的 2A12 铝合金腐蚀预测方法研究[J]. 装备环境工程, 2014, 11(6): 22—28.  
WANG An-dong, CHEN Yue-liang, ZHANG Yong, et al. The Research on 2A12 Aluminum Corrosion Prediction Method Based on Gray Markov Model[J]. Equipment Environmental Engineering, 2014, 11(6): 22—28.

[3] 黄海军, 李婵, 王俊. 典型大气腐蚀介质的灰色预测模型分析[J]. 装备环境工程, 2012, 9(1): 13—16.

- HUANG Hai-jun, LI Chan, WANG Jun. Study on Grey Prediction Model of Typical Atmospheric Corrosion Mediums[J]. Equipment Environmental Engineering, 2012, 9(1): 13—16.
- [4] ZHI Y J, FU D M, WANG H L. Non-equidistant GM(1,1) Model Based on GCHM-WBO and Its Application to Corrosion Rate Prediction[C]// Leicester: Proceedings of IEEE International Conference on Grey Systems and Intelligent Services, 2015: 272—276.
- [5] 刘成臣, 徐胜, 王浩伟, 等. 基于灰色模型和神经网络的铝合金腐蚀预测对比[J]. 装备环境工程, 2013, 9(1): 1—4.
- LIU Cheng-chen, XU Sheng, WANG Hao-wei, et al. Comparative Study of Prediction Models of Aluminum Alloys Based on Gray Model and Artificial Neural Network[J]. Equipment Environmental Engineering, 2013, 9(1): 1—4.
- [6] 周立建, 穆志韬, 邢玮, 等. 基于灰色神经网络的有机涂层寿命预测研究[J]. 装备环境工程, 2011, 8(5): 62—66.
- ZHOU Li-jian, MU Zhi-tao, XING Wei, et al. Study of Service Life Prediction of Organic Coatings Based on Grey Neural Network[J]. Equipment Environmental Engineering, 2011, 8(5): 62—66.
- [7] 萧彧星, 吴光海, 孙宁, 等. BP神经网络在碳钢和低合金钢大气腐蚀数据预测中的应用[J]. 腐蚀科学与防护技术, 2011, 23(2): 171—174.
- XIAO Yu-xing, WU Guang-hai, SUN Ning, et al. Application of Artificial Neural Network on Prediction of Atmospheric Corrosion Data for Carbon Steel and Low Alloy Steel[J]. Corrosion Science and Protection Technology, 2011, 23(2): 171—174.
- [8] 邓志安, 李姝仪, 李晓坤, 等. 基于模糊神经网络的海洋管线腐蚀速率预测新方法[J]. 中国腐蚀与防护学报, 2015, 35(6): 571—576.
- DENG Zhi-an, LI Shu-yi, LI Xiao-kun, et al. A Prediction Method Based on Fuzzy Neural Network for Corrosion Rate of Marine Pipelines[J]. Journal of Chinese Society for Corrosion and Protection, 2015, 35(6): 571—576.
- [9] TIAN Y J, LIU Y, CHENG G J, et al. PCA-FNN Based Performance Prediction for Water Injection in Oilfields[J]. Advanced Materials Research, 2014, 909: 410—417.
- [10] FU Z N, XIE H W. Wind Speed Forecasting Based on FNN in Wind Farm[J]. Applied Mechanics and Materials, 2014, 651—653: 1117—1122.
- [11] GHIASI M M, ARABLOO M, MOHAMMADI A H, et al. Application of ANFIS Soft Computing Technique in Modeling the CO<sub>2</sub> Capture with MEA, DEA, and TEA Aqueous Solutions[J]. International Journal of Greenhouse Gas Control, 2016, 49: 47—54.
- [12] SEIDL D, JANCÍKOVÁ Z, KOŠTIAL P, et al. Exploitation of Artificial Intelligence Methods for Prediction of Atmospheric Corrosion[J]. Defect and Diffusion Forum, 2012, 326—328: 65—68.
- [13] 付青文. 基于规则约简的模糊神经网络模型的研究[D]. 广州: 华南理工大学, 2012.
- FU Qing-wen. A Research of Fuzzy Neural Network Model Based on Rules Reduction[D]. Guangzhou: South China University of Technology, 2012.
- [14] 张小娟. 自适应神经模糊推理系统(ANFIS)及其仿真[J]. 电子设计工程, 2012, 20(5): 11—13.
- ZHANG Xiao-juan. Study on the Adaptive Network-based Fuzzy Inference System and Simulation[J]. Electronic Design Engineering, 2012, 20(5): 11—13.
- [15] 陈瑞敏, 吴雁, 康文英, 等. 连续雾霾天气污染物浓度变化及天气形势特征分析[J]. 气候与环境研究, 2014, 19(2): 209—218.
- CHEN Rui-min, WU Yan, KANG Wen-ying, et al. Analysis of Pollutant Concentrations and Characteristics of Continuous Smoggy Weather[J]. Climatic and Environmental Research, 2014, 19(2): 209—218.